

Facultad de Ciencias, UNAM  
Reconocimiento de patrones y aprendizaje automatizado  
Tarea 1

Rubí Rojas Tania Michelle

6 de enero de 2021

1. Considera la siguiente expresión para calcular los elementos de un conjunto de punto flotante

$$2(\beta - 1)\beta^{l-1}(L - l + 1) + 1$$

donde  $\beta$  es la base,  $L$  es el exponente más grande y  $l$  el más pequeño. Calcula todos los elementos para los siguientes valores  $\beta = 2$ ,  $L = 2$  y  $l = -1$ , donde los números tienen 3 cifras significativas.

Construye todos los números de este conjunto F.

SOLUCIÓN:

$$\begin{aligned} 2(\beta - 1)\beta^{l-1}(L - l + 1) + 1 &= 2(2 - 1)2^{-1-1}(2 - (-1) + 1) + 1 \\ &= 2(3)2^{-2}(3 + 1) + 1 \\ &= 6 \left(\frac{1}{4}\right) (4) + 1 \\ &= \left(\frac{6}{4}\right) 5 \\ &= \left(\frac{3}{2}\right) 5 \\ &= \frac{15}{2} \end{aligned}$$

2. Determina el condicionamiento de la siguiente función:

$$f(x) = \sqrt{x-1} - \sqrt{x}$$

3. Implementa los algoritmos de la bisección y de newton en un script. Muestra su funcionamiento con la siguiente función

$$g(x) = x^3 - x - 1$$

4. Usa los métodos implementados en la pregunta 3 para encontrar  $x^*$  que soluciona  $g(x^*) = 0$  y  $h(x^*) = 0$  en las siguientes funciones

$$g(x) = \cos(x) - x$$

en el intervalo  $[\frac{1}{2}, 1]$ , y

$$h(x) = x^2 - x - 1$$

en el intervalo  $[1, 2]$ . En este caso, la tolerancia debe ser mínimo de  $10^{-8}$ .

5. Muestra que el polinomio característico  $p(\lambda)$  de una matriz  $A \in \mathcal{R}^{2 \times 2}$  se puede expresar como

$$p(\lambda) = \lambda^2 - \lambda \operatorname{tr}(A) + \det(A)$$

donde  $\operatorname{tr}(A)$  es la traza de la matriz  $A$  y  $\det(A)$  es el determinante de la misma.

*Demostración.* Sea  $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \in M_{2 \times 2}(R)$ . Entonces, tenemos que

$p(\lambda) = \det(A - \lambda I_n)$	definición de $p(\lambda)$
$= \det \left( \begin{pmatrix} a & b \\ c & d \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)$	multiplicación escalar de matrices
$= \det \left( \begin{pmatrix} a & b \\ c & d \end{pmatrix} - \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} \right)$	sustituyendo valores
$= \det \left( \begin{pmatrix} a - \lambda & b \\ c & d - \lambda \end{pmatrix} \right)$	resta de matrices
$= (a - \lambda)(d - \lambda) - bc$	definición del determinante
$= ad - a\lambda - d\lambda + \lambda^2 - bc$	álgebra
$= ad - (a + d)\lambda + \lambda^2 - bc$	factorizando
$= \lambda^2 - (a + d)\lambda + (ad - bc)$	reacomodando la expresión
$= \lambda^2 - \operatorname{tr}(A)\lambda + \det(A)$	definición de $\operatorname{tr}(A)$ y $\det(A)$
$= \lambda^2 - \lambda \operatorname{tr}(A) + \det(A)$	conmutatividad de la multiplicación

Por lo tanto, el polinomio característico de la matriz  $A$  puede ser expresado como

$$p(\lambda) = \lambda^2 - \lambda \operatorname{tr}(A) + \det(A)$$

□

6. Utiliza el algoritmo de KNN con el dataset "`trees.csv`". Este dataset cuenta con tres variables o atributos: el diámetro a la altura del pecho, la altura y el volumen de varios árboles. Utilizando los notebooks provistos en clase, responde:

a) Define dos variables independientes y una dependiente. Justifica tu elección.

SOLUCIÓN: Definimos a las variables "`Girth`" y "`Height`" como independientes y a la variable "`Volume`" como dependiente. La elección la realizamos de esta forma porque es más sencillo medir la altura y el diámetro a la altura del pecho, que medir el volumen de los árboles (estuve leyendo un poco al respecto, y para calcular el volumen sin necesidad de talar el árbol se necesitan algunas técnicas complicadas y muy tardadas). Por lo que, es útil poder predecir el volumen del árbol a partir de la altura y el diámetro dados.

b) Normaliza las variables, ¿para qué hacemos esto?

SOLUCIÓN: Para que funcionen mejor muchos algoritmos de *Machine Learning* hay que normalizar las variables de entrada al algoritmo. Normalizar significa, en este caso, comprimir o extender los valores de la variable para que estén en un rango definido.

c) Separa tu dataset en conjunto de entrenamiento y conjunto de prueba. ¿Por qué hacemos esto?

SOLUCIÓN: Una vez que seleccionamos el mejor modelo que se puede crear con los datos disponibles, se tiene que comprobar su capacidad prediciendo nuevas observaciones que no se hayan

empleado para entrenarlo, de esta forma se verifica si el modelo se puede generalizar. Una estrategia para hacer esto es dividir (de manera aleatoria, o no) los datos en dos grupos, ajustar el modelo con el primer grupo y estimar la precisión de las predicciones con el segundo conjunto. El tamaño adecuado para las particiones depende de la cantidad de datos disponibles y la seguridad que se necesite en la estimación del error, pero en general dividir el conjunto en un 80 – 20 (entrenamiento - prueba) suele dar buenos resultados.

- d) Encuentra la  $k$  óptima para aplicar el algoritmo.

SOLUCIÓN:

- e) Obtén el MSE del modelo calibrado aplicado al conjunto de prueba.

SOLUCIÓN:

7. Utiliza el método de regresión lineal, o en otras palabras, ajusta un modelo lineal a las observaciones del dataset "`trees.csv`". Utiliza la misma definición de variables independientes y dependientes del ejercicio anterior, así como el mismo conjunto de entrenamiento y de prueba. Responde:

- a) ¿Cuál es el MSE del modelo lineal que construiste?

SOLUCIÓN: El MSE obtenido fue de 7.86 usando regresión lineal múltiple.

```
Mean Absolute Error: 2.08
Mean squared error: 7.86
Root Mean Squared Error: 2.80
Variance score: 0.84
```

- b) Comparando el MSE de este modelo con el del modelo anterior, ¿cuál es menor? ¿a qué piensas que se debe?

SOLUCIÓN: